

ISI KONTEN PRESENTASI UAS — KELOMPOK 5

Klasifikasi Risiko Diabetes dengan Decision Tree, Random Forest, dan SVM | Fokus 1 Dataset (Diabetes Data)

SLIDE 1

Judul

- Judul besar: **Klasifikasi Risiko Diabetes Menggunakan Decision Tree, Random Forest, dan SVM**
- Subjudul: Ujian Akhir Semester Praktikum Machine Learning
- Nama kelompok: Kelompok 5, Teknik Informatika, Universitas Islam Riau
- Cantumkan logo kampus dan mata kuliah jika ada template resmi dari jurusan

SLIDE 2

Anggota Kelompok

- Sandy Satria Nugraha
- Nuraini Gusnita Sari
- Mutia Aulia Agustin
- Meisyah Ababil
- Nanda Saputra
- Muhammad Rizqy Ramadhan
- Fadhulul Wafin

SLIDE 3

Latar Belakang dan Tujuan Penelitian

- Diabetes adalah salah satu penyakit tidak menular dengan prevalensi tinggi dan berdampak besar pada kualitas hidup penderita jika tidak terdeteksi sejak dini
- Deteksi dini berbasis data indikator kesehatan dapat membantu proses skrining awal sebelum pemeriksaan medis lanjutan
- Tujuan penelitian ini membangun model klasifikasi yang mampu memprediksi status diabetes seseorang berdasarkan 17 indikator kesehatan
- Penelitian membandingkan tiga algoritma klasifikasi populer, yaitu Decision Tree, Random Forest, dan Support Vector Machine, untuk menemukan model yang paling optimal pada dataset ini

SLIDE 4

Deskripsi Dataset

- Sumber dataset diberikan oleh dosen pengampu sesuai nomor kelompok
- Jumlah data 80 sampel dengan 17 fitur prediktor dan 1 kolom target
- Target bernama **Diabetes**, bersifat biner, F artinya tidak diabetes dan T artinya diabetes
- Fitur mencakup tiga kelompok besar, yaitu indikator klinis (HighBP, HighChol, Stroke, HeartDiseaseorAttack), gaya hidup (Smoker, PhysActivity, Fruits, Veggies, HvyAlcoholConsump), dan kondisi kesehatan umum (BMI, GenHlth, MentHlth, PhysHlth, Age)
- Distribusi kelas seimbang sempurna, 40 sampel F dan 40 sampel T

SLIDE 5

Hasil Exploratory Data Analysis (EDA)

- Tidak ditemukan missing value maupun data duplikat pada seluruh 18 kolom
- Fitur paling berkorelasi dengan target adalah HighBP (0.50), GenHlth (0.50), DiffWalk (0.46), HighChol (0.38), dan Age (0.38)
- Tidak ditemukan indikasi multicollinearity ekstrem antar fitur prediktor
- Outlier ditemukan pada BMI namun secara medis wajar (berkaitan dengan obesitas), sehingga dipertahankan dan tidak dihapus

Tampilkan *heatmap* korelasi dan *bar chart* korelasi tertinggi sebagai visual pendukung slide ini

SLIDE 6

Data Cleaning dan Pre Processing

- Data cleaning menyimpulkan dataset sudah bersih, tidak perlu imputasi maupun penghapusan baris
- Encoding dilakukan pada kolom target menggunakan LabelEncoder, F menjadi 0 dan T menjadi 1
- Seluruh fitur prediktor sudah berbentuk numerik sejak awal sehingga tidak memerlukan encoding tambahan
- Feature scaling dilakukan secara selektif, hanya diterapkan pada model SVM melalui Pipeline bersama StandardScaler, karena Decision Tree dan Random Forest tidak sensitif terhadap skala fitur

SLIDE 7

Feature Engineering dan Split Dataset

- Fitur (X) dan target (y) dipisahkan, menghasilkan 17 fitur prediktor
- Tidak dilakukan feature selection tambahan karena seluruh fitur memiliki relevansi domain terhadap risiko diabetes dan tidak ditemukan korelasi ekstrem antar fitur
- Data dibagi dengan proporsi 80 banding 20, menghasilkan 64 data latih dan 16 data uji
- Parameter stratify digunakan agar proporsi kelas F dan T tetap seimbang pada data latih maupun data uji

SLIDE 8

Modeling: Tiga Algoritma Klasifikasi

- **Decision Tree Classifier**, model berbasis struktur pohon keputusan yang membagi data berdasarkan threshold fitur
- **Random Forest Classifier**, model ensemble berbasis bagging dari banyak Decision Tree untuk meningkatkan generalisasi
- **Support Vector Machine (SVM)**, model berbasis pencarian hyperplane pemisah optimal, dibungkus dalam Pipeline bersama StandardScaler
- Ketiga model dilatih dengan parameter default terlebih dahulu sebagai baseline sebelum tuning

SLIDE 9

Evaluasi Sebelum Hyperparameter Tuning

- Decision Tree (Default): Accuracy 0.50, Precision 0.50, Recall 0.375, F1 Score 0.4286, ROC AUC 0.50
- Random Forest (Default): Accuracy 0.625, Precision 0.75, Recall 0.375, F1 Score 0.50, ROC AUC 0.7812
- SVM (Default): Accuracy 0.75, Precision 0.70, Recall 0.875, F1 Score 0.7778, ROC AUC 0.8906
- Decision Tree default sangat overfitting, performanya setara tebakan acak, karena tidak ada batasan kedalaman pohon

Tampilkan confusion matrix dan ROC curve ketiga model sebagai visual pendukung

SLIDE 10

Hyperparameter Tuning

- Metode tuning menggunakan GridSearchCV dengan skema StratifiedKFold 5 fold
- Decision Tree, parameter terbaik criterion gini, max_depth 5, min_samples_split 5, min_samples_leaf 1
- Random Forest, parameter terbaik max_depth 5, max_features sqrt, min_samples_leaf 1, n_estimators 200
- SVM, parameter terbaik C 1, gamma 0.1, kernel rbf
- StratifiedKFold dipilih agar proporsi kelas tetap terjaga di setiap fold, penting untuk dataset kecil

SLIDE 11

Evaluasi Sesudah Hyperparameter Tuning

- Decision Tree (Tuned): Accuracy naik dari 0.50 menjadi 0.625, ROC AUC naik dari 0.50 menjadi 0.7344
- Random Forest (Tuned): Accuracy naik dari 0.625 menjadi 0.6875, ROC AUC naik dari 0.7812 menjadi 0.8281
- SVM (Tuned): Accuracy tetap di 0.75, namun ROC AUC naik dari 0.8906 menjadi 0.9062
- Tuning terbukti membantu terutama pada Decision Tree yang sebelumnya overfitting, sementara SVM sudah cukup optimal sejak kondisi default

Tampilkan grafik bar perbandingan accuracy sebelum vs sesudah tuning

SLIDE 12

Model Terbaik dan Testing

- Model terbaik terpilih adalah **SVM (Tuned)** dengan Accuracy 0.75 dan ROC AUC 0.9062
- Pada tahap testing, model memprediksi benar 12 dari 16 data uji, atau salah pada 4 data uji
- Precision 0.70, Recall 0.875, F1 Score 0.7778
- Recall yang tinggi penting dalam konteks medis, karena model lebih baik salah menandai orang sehat sebagai berisiko daripada melewatkan kasus diabetes yang sebenarnya positif

SLIDE 13

Kesimpulan

- SVM terbukti menjadi model paling optimal untuk dataset Diabetes ini, unggul dalam ROC AUC yang menandakan kemampuan membedakan kelas yang baik
- Fitur HighBP, GenHlth, dan DiffWalk terbukti menjadi indikator risiko diabetes yang paling kuat pada dataset ini, sejalan dengan pengetahuan medis umum
- Hyperparameter tuning terbukti membantu terutama pada model yang rawan overfitting seperti Decision Tree
- Keterbatasan penelitian terletak pada ukuran data uji yang kecil, hanya 16 sampel, sehingga setiap satu sampel berpengaruh sekitar 6 poin persen terhadap accuracy

SLIDE 14

Penutup

- Ucapan terima kasih
- Sesi tanya jawab UAS teori